

Técnicas de Análise de Dados Aplicadas a Biopotenciais no Treinamento de Pilotos do Motosport

Orientador: Prof. Dr. Wellington Cássio Pinheiro

Departamento: Engenharia Mecânica

Candidato: Mateus Marana Assuena

Nº:22.123.026-1

Início: abril/2025

Previsão conclusão: março/2026

RESUMO

Este projeto visa investigar o efeito da fadiga muscular nos pilotos de *motorsport* utilizando técnicas de análise de dados aplicada a biopotenciais. O foco será a implementação de algoritmos de inteligência artificial e *machine learning* para relacionar a performance e a exposição prolongada a exercícios físicos intensos com a fadiga muscular. Dados preliminares foram coletados com voluntários das equipes do BAJA e Fórmula da FEI realizando exercícios na academia com ênfase grupos musculares flexores e extensores de punho, apontados pelos pilotos como intensamente demandados durante as corridas. O projeto utilizará a eletromiografia de superfície (sEMG) para entender a atividade elétrica muscular durante as etapas do percurso e como a fadiga afeta o desempenho do atleta. Espera-se que, por meio de técnicas de aprendizagem de máquina, as análises realizadas identifiquem padrões relevantes, permitindo a mitigação dos impactos da fadiga nos atletas do automobilismo e gerando *insights* sobre a preparação dos pilotos.

Palavras-chave: motorsport; análise de dados; clusterização; classificação; inteligência artificial; machine learning; fadiga muscular; eletromiografia.

1 REVISÃO DE LITERATURA

1.1 Introdução e contextualização

O *motorsport* é uma das modalidades esportivas mais populares do mundo (Ferguson, D. P.; Davis, A. M.; Lightfoot, J. T., 2015). Competições como Fórmula 1 e NASCAR atraem telespectadores de todo o mundo, contando com uma audiência de 5 milhões de pessoas por evento (Ferguson, D. P.; Davis, A. M.; Lightfoot, J. T., 2015). Por envolver velocidade, é uma modalidade de alta intensidade que exige dos pilotos boa resistência física e capacidade cognitiva para praticá-lo (Ferguson, David P.; Davis, Adam M.; Lightfoot, J. Timothy, 2007)

Com base na Fédération Internationale de l'Automobile (FIA), a indústria do *motorsport* gera um volume bruto anual estimado em cerca de € 159,2 bilhões e emprega aproximadamente 1,5 milhão de trabalhadores pagos em todo o mundo (FIA. . . , 2021). Nos Estados Unidos, estudo da Performance Racing Industry (PRI) indicou um impacto econômico superior a US\$ 69,2 bilhões anuais e emprega mais de 318 mil pessoas nos diversos elos da cadeia do automobilismo (NEW. . . , 2025).

De acordo com o estudo conduzido por Hoyes e Collins (2018), os pilotos de automobilismo relatam qual é o principal requisito físico necessário para o desempenho ideal durante as corridas, segundo suas experiências (Hoyes; Collins, 2018). Os autores destacam que, embora força e estabilidade também sejam importantes, a resistência cardiorrespiratória é considerada pelos próprios atletas como o fator mais determinante para suportar as demandas fisiológicas das competições.

Estudos mostram que sessões prolongadas de condução levam à fadiga neuromuscular, reduzindo a precisão motora e a eficiência de resposta muscular (Lecocq *et al.*, 2020). A análise de biopotenciais e sinais inerciais se destaca como um conjunto de técnicas que podem ser utilizadas para compreender melhor a biomecânica dos pilotos e permitir o entendimento de como a fadiga muscular afeta o desempenho na prática do esporte.

A fadiga muscular é definida como uma diminuição transitória da capacidade de realizar ações físicas, ou seja, uma redução momentânea no desempenho muscular mesmo antes da falha completa (Enoka; Duchateau, 2007). Esse fenômeno influencia diretamente a função muscular, uma vez que altera o recrutamento das unidades motoras e as propriedades de condução das fibras, modificando a amplitude e a frequência dos sinais eletromiográficos durante o esforço prolongado.

O objetivo principal deste estudo é aplicar métodos de aprendizado de máquina e inteligência artificial, na análise da fadiga muscular dos pilotos. Por meio desses modelos, pretende-se identificar padrões relevantes nos sinais de sEMG e inerciais que indiquem estados de fadiga, provendo análise que possam orientar os profissionais da saúde na elaboração de programas de treinamento mais personalizados e estratégias de competição que reduzam perdas de desempenho relacionadas a esforço muscular excessivo, otimizando tanto os treinos quanto o rendimento em competições.

1.2 Biomecânica dos Pilotos

Biomecânica é o estudo do movimento das coisas vivas (Knudson, 2007), utilizando-a podemos entender melhor como o corpo humano e, neste estudo, os atletas do motorsport, se utilizam de forças de contração muscular e torques articulares na produção de movimentos e como esses movimentos se coordenam para a execução de uma tarefa. Em particular, o estudo da biomecânica é uma ferramenta para entender e aperfeiçoar o desempenho humano (Enoka, 2015).

Considerando que o automobilismo é um esporte de alta intensidade, a ativação muscular e neurológica exigida para controlar o veículo e realizar tomadas rápidas de decisão pode comprometer o sistema motor dos pilotos. Em situações de uso prolongado, há risco de fadiga localizada, que reduz a precisão contrátil e prejudica o desempenho competitivo (Mills *et al.*, 2025).

A fadiga é um fenômeno multifatorial que resulta em redução temporária da capacidade funcional do sistema nervoso e da força muscular (Aquino *et al.*, 2022). Sendo vista em várias atividades que necessitam de esforço do indivíduo, ela pode acarretar em um série de fatores que, em períodos mais longos, resultam em problemas de saúde. Alguns de seus efeitos registrados são o cansaço, lapsos cognitivos e a perda de performance a longo prazo (Wingelaar-Jagt *et al.*, 2020). A fadiga muscular é caracterizada pela redução prolongada da capacidade de gerar força, sendo associada ao aumento da amplitude da sEMG e à transição da alta para a baixa frequência (Shair *et al.*, 2017).

Um estudo realizado mostra que as voltas iniciais dos competidores são na maioria das vezes as melhores enquanto as últimas são comprometidas. Credita-se esse comprometimento ao desgaste físico e mental acumulado (Franceschini; Terzini; Zanetti, 2017). Para mitigar esses efeitos, estratégias como pausas para recuperação muscular e sessões de treino mais curtas,

seguidas de análises detalhadas dos erros, podem ser eficazes (Franceschini; Terzini; Zanetti, 2017). Essa abordagem visa preservar o desempenho durante períodos mais longos e reduzir a incidência de fadiga severa.

Estudo de Delmuns Carvajal et al. (2023) apontou que os membros superiores dos pilotos de kart estão sujeitos a variações significativas na atividade muscular devido a fatores como o desenho da pista, a lateralidade do piloto e a presença de sistemas de embreagem. Por exemplo, curvas realizadas no lado dominante do piloto resultam em maior ativação muscular, enquanto a troca de marchas acrescenta esforço adicional, alterando os padrões de movimento.

Os membros superiores estendem-se da cintura escapular, composta por escápula, clavícula e articulação glenoumeral, até a mão, englobando ombro, braço e antebraço (Kenhub, 2023b). O braço contém o úmero e músculos dos compartimentos anterior (bíceps, coracobraquial e braquial) e posterior (tríceps), enquanto o antebraço é composto pelos ossos rádio e ulna, e pelos músculos dos compartimentos flexor e extensor, incluindo flexor radial do carpo, flexor ulnar do carpo, pronador redondo, supinador, extensores dos dedos e extensores do carpo sendo inervado pelos nervos mediano, ulnar e radial. A mão apresenta ossos carpais, metacarpos e falanges, com músculos que garantem precisão e força (Kenhub, 2023c).

Os membros inferiores vão da cintura pélvica (ilíaco, ísquio e púbis) até o pé, compreendendo coxa e perna (Kenhub, 2023a). A coxa abriga o fêmur e músculos dos grupos quadríceps e isquiotibiais; a perna contém tíbia e fíbula, com músculos gastrocnêmio, sóleo e tibial anterior; e o pé é formado por ossos do tarso, metatarso e falanges, sustentados por músculos responsáveis pela estabilidade e propulsão (Fehrenbach; Herring, 2020).

As articulações dos membros superiores incluem a glenoumeral, cotovelo, rádio-ulnares, punho e interfalângicas, que permitem movimentos como flexão, extensão e rotação (Smith; Patel, 2019). Durante a condução, atuam no controle do volante, trocas de marcha e estabilização do tronco, com amplitudes médias de 14°–54° no ombro, 35°–72° no cotovelo e 34°–23° no punho (Reed; Manary, 2018), além de alta ativação muscular em manobras rápidas (Andersson; Johansson, 2020). A operação dos pedais exige forte ativação dos isquiotibiais, gastrocnêmio e reto femoral, com torques maiores no quadril, seguidos de joelho e tornozelo (Kim; Lee, 2022). Em frenagens de emergência, motoristas idosos exibem maior ativação do sóleo e atraso no reto femoral, sugerindo maior demanda muscular (Watanabe; Nagai, 2021).

1.3 Biopotenciais e Eletromiografia

Biopotenciais são sinais elétricos gerados por processos fisiológicos que ocorrem dentro do corpo. São produzidos a partir da atividade eletroquímica de uma célula excitável. Quando estimulada, uma célula excitável gera um potencial de ação, a qual é a fonte essencial dos processos biopotenciais no corpo (Macy, 2017).

O sEMG capta a atividade elétrica das fibras musculares durante contrações voluntárias ou involuntárias, por meio de eletrodos colocados sobre a pele. Ele permite estimar parâmetros como intensidade de ativação e recrutamento de unidades motoras, servindo como ferramenta para investigar o comportamento funcional dos músculos durante diferentes tipos de esforço (Farina, 2016; Merletti; Farina, 2023). A EMG de superfície, em particular, é amplamente empregada na avaliação da fadiga muscular e do controle motor, desempenhando papel essencial em contextos clínicos e esportivos (De Luca; Merletti; Farina, 2016).

A aplicação desses métodos nos diferentes domínios proporciona uma compreensão mais aprofundada dos processos fisiológicos envolvidos na fadiga muscular, contribuindo significativamente para melhorar o desempenho em atividades de longa duração.(Shair *et al.*, 2017)

1.4 IMUs

Os sensores IMU (Unidade de Medição Inercial) são amplamente utilizados para capturar e analisar o movimento humano em diversas aplicações, incluindo biomecânica e reabilitação. Esses dispositivos combinam acelerômetros, giroscópios e, em alguns casos, magnetômetro. Sua precisão na análise do movimento tem sido demonstrada em estudos recentes, destacando sua importância na avaliação clínica e na validação de desempenho em diversas tarefas motoras (Meng *et al.*, 2023; Favata *et al.*, 2024).

- a) **Acelerômetro:** Mede a aceleração linear em três eixos (X, Y e Z), sendo essencial para identificar os impactos e forças aplicadas nos membros superiores durante curvas e frenagens. Essas informações ajudam a entender como as forças G afetam o corpo do piloto em diferentes situações de corrida.
- b) **Giroscópio:** Registra a velocidade angular, captando rotações e inclinações do tronco e dos membros superiores. Esse sensor será útil para analisar a dinâmica de manobras rápidas, como mudanças de direção e estabilização após curvas.

- c) **Magnetômetro:** Detecta a orientação em relação ao campo magnético terrestre, permitindo um monitoramento preciso da direção do corpo e da postura do piloto no espaço tridimensional.

Os sensores Trigno Avanti™ incluem uma unidade de medição inercial (IMU) integrada com nove graus de liberdade (9-DOF). Esses sensores permitem registrar as medidas inerciais de forma sincronizada aos sinais EMG (Delsys Inc., 2019). As faixas típicas de operação variam de ± 2 g a ± 16 g para o acelerômetro e $\pm 250^\circ/\text{s}$ a $\pm 2000^\circ/\text{s}$ para o giroscópio, garantindo alta precisão na análise de movimento e postura dos participantes (Delsys Inc., 2019).

Table 1 – Especificações técnicas dos sensores utilizados no sistema *Trigno™ Wireless EMG* (Delsys Inc.)

Parâmetro	Especificação Técnica
Fabricante / Modelo	Delsys Inc., Boston, EUA — Sistema <i>Trigno™ Wireless EMG</i>
Tipo de sensor	Eletromiografia de superfície (EMG) sem fio, com opção de módulo inercial (IMU) integrado
Faixa de frequência (banda passante)	20 – 450 Hz (filtro analógico passa-faixa interno Butterworth de 4ª ordem)
Taxa de amostragem	2000 Hz por canal (configuração padrão para EMG); até 4000 Hz em modo de alta resolução
Resolução do conversor A/D	16 bits
Faixa de entrada	± 11 mV (ajustável até ± 22 mV)
Ruído de fundo	≤ 750 nV RMS
Latência de transmissão	Inferior a 500 μs (transmissão digital sem fio de baixa latência)
Precisão temporal entre sensores	± 1 μs de defasagem máxima entre canais sincronizados
Distância operacional	Até 40 m (linha de visada direta)
Autonomia da bateria	Aproximadamente 8 horas de operação contínua
Dimensões / Massa	37 × 26 × 15 mm / 14 g
Material dos eletrodos	Prata pura (99,99 %) com encapsulamento em polímero selado
IMU integrada (opcional)	Acelerômetro triaxial (± 16 g), giroscópio ($\pm 2000^\circ/\text{s}$) e magnetômetro (± 4900 μT)
Interface de software	Compatível com <i>EMGworks®</i> , <i>Trigno SDK</i> , e integração via MATLAB®/Python®
Ambiente operacional	5–40 °C, umidade relativa ≤ 80 % (sem condensação)

1.5 Aplicação da RMS na Análise de Fadiga no Motorsport

A *Root Mean Square* (RMS) é uma métrica estatística utilizada para mensurar a magnitude efetiva de sinais variáveis, especialmente em contextos biomédicos e de engenharia em que sua fórmula, para um sinal discreto $x[n]$ com N amostras, é dada por:

$$\text{RMS} = \sqrt{\frac{1}{N} \sum_{n=1}^N x[n]^2} \quad (1)$$

essa medida permite representar a intensidade média de um sinal oscilatório sendo amplamente utilizada na análise de sinais eletromiográficos por sua capacidade de refletir a amplitude e a variabilidade do sinal em função da atividade muscular (De Luca, 1997). À medida que a fadiga se instala, observa-se uma tendência de aumento na amplitude do sinal elétrico captado em razão da necessidade de maior recrutamento de unidades motoras para compensar a perda de eficiência muscular (Gandevia, 2001).

Adicionalmente, ao segmentar o sinal em janelas de duração fixa, pode-se calcular a RMS de cada trecho, obtendo uma análise dinâmica da fadiga ao longo do tempo (Merletti; Parker, 2004).

1.6 Média da Amplitude da Variação (MAV) na Análise de Fadiga no Motorsport

A Média da Amplitude da Variação (MAV) é um parâmetro utilizado na análise de sinais eletromiográficos por sua simplicidade de cálculo e eficácia na detecção de alterações relacionadas à fadiga muscular. A MAV é definida como a média dos valores absolutos da amplitude do sinal em uma janela de tempo, permitindo uma quantificação direta da atividade elétrica do músculo. Sua fórmula pode ser expressa como:

$$\text{MAV} = \frac{1}{N} \sum_{i=1}^N |x_i|$$

em que x_i representa a i -ésima amostra do sinal e N é o número total de amostras dentro da janela de análise (Phinyomark; Phukpattaranont; Limsakul, 2012).

Durante períodos prolongados de esforço físico, observa-se um aumento da amplitude do sinal EMG associado à necessidade de recrutamento de um maior número de unidades motoras para manter o desempenho, seguido por uma redução conforme a fadiga muscular se instala (De Luca, 1997).

Além disso, a integração da MAV com outras métricas, como a RMS, potencializa a análise multidimensional da fadiga (Merletti; Parker, 2004). Essa abordagem permite identificar períodos críticos de declínio do desempenho do piloto, fornecendo informações relevantes para estratégias de treinamento, ergonomia e ajuste da carga de trabalho durante a competição (Phinyomark; Phukpattaranont; Limsakul, 2012; De Luca, 1997).

1.7 Espectrograma e Análise da Fadiga em Motorsport

O espectrograma é uma ferramenta utilizada na análise de sinais biológicos, permitindo a visualização conjunta das componentes de frequência ao longo do tempo em um sinal. Ele é obtido por meio de *Short-Time Fourier Transform*, que divide o sinal em janelas temporais e aplica a transformada de Fourier em cada segmento, resultando em uma representação tempo-frequência e sua formulação matemática pode ser descrita como:

$$X(\tau, \omega) = \sum_{n=-\infty}^{\infty} x[n] w[n - \tau] e^{-j\omega n} \quad (2)$$

em que $x[n]$ é o sinal original, $w[n]$ é a janela de análise, τ representa o deslocamento temporal e ω a frequência angular (Allen, 1977). Essa abordagem permite identificar como a energia do sinal se distribui ao longo do tempo em diferentes bandas de frequência.

Na análise da fadiga muscular, o espectrograma aplicado a sinais EMG permite observar alterações na distribuição espectral ao longo do tempo. Durante o progresso da fadiga, é comum um deslocamento da energia para bandas de baixa frequência, refletindo aumento de potência nessas regiões e redução da variabilidade espectral (Puce *et al.*, 2021; Rodrigues *et al.*, 2022)

2 MATERIAIS E MÉTODOS

2.1 Métodos

Primeiramente, foi realizado um aprofundamento da revisão de literatura aqui apresentada, com o objetivo de aprimorar os conhecimentos em biomecânica dos pilotos, eletromiografia e machine learning na análise de dados. De forma concomitante, foi realizada a familiarização com tópicos da biomecânica computacional importantes à execução da pesquisa.

A coleta de dados foi realizada na academia do campus com os pilotos do Fórmula FEI e BAJA, utilizando de exercícios que simulam a pilotagem de carros de corrida, focando nos músculos presentes no antebraço. A eletromiografia de superfície foi empregada para monitorar

a ativação muscular dos pilotos durante o esforço físico. O processo de coleta foi dividido em etapas, a fim de identificar padrões distintos de fadiga e desempenho muscular.

A atividade eletromiográfica foi registrada por meio do sistema *Trigno™ Wireless EMG* (Delsys Inc., Boston, EUA), composto por sensores sem fio, posicionados sobre os músculos Braquiorradial, Extensor do Carpo Ulnar, Extensor dos Dedos e Palmar Longo. A fixação dos sensores seguiu as recomendações do fabricante, respeitando o alinhamento das fibras musculares e os procedimentos de preparação da pele, a fim de garantir baixa impedância e máxima qualidade do sinal. Entre as séries de coleta, foi adotado um intervalo de recuperação de 10 minutos para minimizar os efeitos de fadiga residual.

O protocolo experimental foi repetido em três dias distintos, com intervalo mínimo de 24 horas entre as sessões, permitindo a análise da variabilidade interdiária e o controle de efeitos adaptativos. Os sinais EMG foram transmitidos em tempo real para a unidade base do sistema, armazenados em ambiente computacional seguro e posteriormente processados para normalização, segmentação e extração de parâmetros relevantes à análise de fadiga muscular.

2.2 Utilização do Sistema Trigno na Coleta de Dados para Análise de Fadiga Muscular

A coleta dos sinais elétricos foi realizada por meio do sistema *Trigno™ Wireless EMG* (Delsys Inc., Boston, EUA). O sistema é composto por sensores sem fio miniaturizados, dotados de eletrodos de prata (99,99 %) encapsulados em corpo selado e resistente, com área de contato típica de 5×1 mm (Inc., 2022c). Os sinais são transmitidos via rádio a uma unidade base receptora, com alcance de até 40 m em condições ideais de visada direta (Inc., 2022a).

Os sensores EMG do sistema Trigno operam com taxa de amostragem de 2 000 Hz por canal, o que permite a captura precisa de componentes de alta frequência do sinal mioelétrico e evita aliasing durante a análise espectral (Inc., 2022a,b). A faixa de frequência efetiva (banda passante) é de 20 Hz a 450 Hz, adequada para a maioria dos estudos de ativação muscular voluntária (Inc., 2022c). A resolução de conversão analógico-digital é de 16 bits, com faixa de entrada típica de ± 11 mV a ± 22 mV, ajustável conforme a configuração experimental (Inc., 2021).

A comunicação entre sensores e unidade base ocorre por transmissão digital sem fio de baixa latência (inferior a 500 μ s), garantindo a sincronização precisa entre múltiplos canais de aquisição (Inc., 2022a).

Cada sensor é alimentado por uma bateria interna recarregável de íons de lítio, com autonomia de operação contínua de até 8 horas. O carregamento é realizado por meio de estações dedicadas, permitindo a rotação dos sensores entre sessões experimentais sem perda de produtividade (Inc., 2022a).

2.3 Procedimento de Coleta de Dados

A coleta de dados foi conduzida com o objetivo de registrar a atividade eletromiográfica (EMG) dos músculos do antebraço durante exercícios de resistência muscular. O experimento foi realizado em ambiente controlado, garantindo condições adequadas de temperatura, iluminação e ausência de interferências eletromagnéticas.

2.3.1 Preparação do participante

Inicialmente, o piloto foi preparado para o experimento por meio de limpeza e depilação da região de interesse, reduzindo a impedância elétrica da pele e garantindo a qualidade dos sinais. Em seguida, foram identificados e demarcados os pontos anatômicos correspondentes aos músculos:

- a) **Braquiorradial,**
- b) **Extensor do Carpo Ulnar,**
- c) **Extensor dos Dedos, e**
- d) **Palmar Longo.**

Os sensores do sistema Trigno foram fixados sobre os ventres musculares, respeitando o alinhamento das fibras e seguindo as recomendações do fabricante quanto à orientação e distância entre eletrodos. Cada sensor foi calibrado individualmente antes do início da coleta, assegurando a estabilidade e fidelidade do sinal durante todo o processo.

2.3.2 Execução do exercício

O protocolo experimental consistiu em três séries do exercício de rosca punho, realizadas até a falha muscular voluntária, com foco na ativação dos músculos extensores e flexores do antebraço. Entre cada série, foi concedido um intervalo de 10 minutos de descanso, a fim de permitir a recuperação parcial e minimizar a influência da fadiga residual.

Durante a primeira sessão, observou-se que a primeira repetição apresentou maior duração, uma vez que o participante demorou mais tempo para atingir a falha muscular.

2.3.3 Sessões experimentais

O protocolo completo foi repetido em três dias distintos, com intervalo de 24 horas entre as sessões. Essa estratégia permitiu avaliar a variabilidade interdiária e controlar possíveis efeitos de aprendizado, adaptação neuromuscular ou fadiga cumulativa.



Figure 1 – Simulação do exercício de rosca punho realizado durante a primeira coleta na academia. O participante manteve o antebraço apoiado e realizou o movimento de flexão e extensão do punho até a falha muscular.



Figure 2 – Simulação do exercício de rosca punho realizado durante a primeira coleta na academia. O participante manteve o antebraço apoiado e realizou o movimento de flexão e extensão do punho até a falha muscular.

O *Trigno Wireless EMG* demonstrou excelente desempenho na captação dos sinais mioelétricos, oferecendo uma ferramenta robusta e precisa para o estudo da fadiga muscular em condições controladas, sem comprometer a liberdade de movimento do participante..

2.4 Pipeline Computacional e Modelo Baseado em PINN

Após a etapa de aquisição do EMG, foi desenvolvido um pipeline computacional responsável pela extração de características, construção de um índice fisiológico de fadiga e treinamento de um modelo baseado em PINNs. Esse pipeline foi estruturado com o objetivo de transformar o sinal bruto em uma representação temporal contínua e interpretável da fadiga muscular.

2.4.1 Extração de características do sinal EMG

Os sinais EMG foram segmentados em janelas temporais de 5 segundos, com o objetivo de reduzir a variabilidade instantânea do sinal e capturar padrões estatísticos mais estáveis.

No domínio temporal, foram extraídas as métricas RMS, MAV e ZCR. O RMS foi utilizado como estimador da potência efetiva do sinal EMG, sendo empregado na literatura como indicador do nível de ativação muscular. O MAV foi calculado para representar a amplitude média

do sinal, fornecendo uma medida complementar da intensidade da atividade eletromiográfica. Já o ZCR foi utilizado para quantificar a taxa de cruzamentos por zero, refletindo a complexidade e o conteúdo de frequência do sinal, parâmetros que tendem a sofrer alterações durante o processo de fadiga muscular.

No domínio da frequência, aplicou-se a Transformada Rápida de Fourier (FFT) após o janelamento do sinal por meio da janela de Hamming, adotada para minimizar efeitos de *leakage* espectral decorrentes da análise de segmentos finitos do sinal. Em seguida, foi realizada uma suavização gaussiana do espectro, visando reduzir flutuações locais e aumentar a robustez da extração das características espectrais.

A partir do espectro suavizado foram obtidas a Frequência Média (MNF), a Frequência Mediana (MDF) e o Desvio Espectral. A MNF e a MDF foram selecionadas por serem reconhecidas como importantes indicadores de fadiga muscular, uma vez que o processo de fadiga está associado ao deslocamento do conteúdo espectral do EMG para faixas de menor frequência. O desvio espectral foi utilizado para caracterizar a dispersão da energia ao longo do espectro de frequências, permitindo avaliar alterações na distribuição espectral do sinal.

Adicionalmente, foi empregada a análise por espectrograma para incorporar informações tempo-frequência ao processo de caracterização dos sinais. A partir dessa representação foram extraídas a energia espectral média e a frequência dominante. A energia espectral foi utilizada como medida da intensidade global da atividade muscular ao longo do tempo, enquanto a frequência dominante permitiu identificar a faixa espectral com maior concentração de energia em cada janela analisada.

A seleção dessas características foi fundamentada em sua relevância fisiológica e em sua ampla utilização em estudos de análise de fadiga muscular baseada em eletromiografia, possibilitando uma representação abrangente das alterações de amplitude e frequência que ocorrem durante o esforço prolongado.

2.4.2 Construção do índice fisiológico de fadiga

Devido à inexistência de um marcador direto e quantitativo capaz de representar instantaneamente o nível de fadiga muscular a partir dos sinais eletromiográficos, foi desenvolvido um índice fisiológico de fadiga utilizado como referência para o treinamento supervisionado do modelo proposto. Esse índice tem como objetivo sintetizar, em uma única variável contínua, as

alterações fisiológicas observadas nas diferentes características extraídas do sinal EMG ao longo do exercício.

Inicialmente, todas as features foram normalizadas para o intervalo, visando eliminar diferenças de escala entre as variáveis e garantir contribuições comparáveis na composição do índice. Em seguida, foi realizada uma combinação ponderada das características temporais e espectrais, considerando o comportamento fisiológico esperado de cada métrica durante o processo de fadiga muscular.

As variáveis RMS, MAV e energia espectral foram incorporadas diretamente ao índice por apresentarem tendência de aumento com a progressão da fadiga. Por outro lado, as métricas ZCR, MNF, MDF e frequência dominante foram invertidas, uma vez que normalmente apresentam redução ao longo do esforço muscular prolongado em decorrência do deslocamento do conteúdo espectral para faixas de menor frequência.

O índice final foi obtido por meio da média ponderada das contribuições provenientes dos diferentes músculos monitorados, permitindo uma representação global do estado fisiológico do antebraço. Posteriormente, foi aplicada uma suavização temporal baseada em média móvel, com o objetivo de reduzir oscilações locais e aumentar a continuidade temporal do sinal resultante.

Dessa forma, o índice fisiológico de fadiga fornece uma aproximação contínua da evolução da fadiga muscular ao longo do exercício, servindo como variável alvo para o treinamento da PINN.

2.4.3 Arquitetura da PINN

O modelo desenvolvido consiste em uma rede neural artificial totalmente conectada, cuja entrada é composta pelas características temporais e espectrais extraídas dos sinais eletromiográficos, acrescidas da informação temporal normalizada. A inclusão explícita do tempo como variável de entrada permite que o modelo aprenda não apenas relações estáticas entre as features e o estado de fadiga, mas também a dinâmica temporal associada à evolução do fenômeno ao longo do exercício.

A arquitetura adotada foi composta por três camadas ocultas contendo 128, 128 e 64 neurônios, respectivamente, todas utilizando função de ativação Tangente Hiperbólica (*Tanh*). A escolha dessa função de ativação foi motivada por sua suavidade e diferenciabilidade contínua em todo o domínio, características importantes em PINNs, uma vez que o processo de treinamento

envolve o cálculo de derivadas de primeira e segunda ordem da saída da rede em relação às variáveis de entrada.

Diferentemente de arquiteturas convencionais voltadas exclusivamente para ajuste de dados, a PINN busca incorporar informações relacionadas ao comportamento físico esperado do sistema analisado. Dessa forma, a utilização de funções suaves contribui para a obtenção de aproximações contínuas e fisiologicamente plausíveis da evolução da fadiga muscular.

A saída da rede consiste em um único valor escalar para cada instante analisado, representando a estimativa contínua do índice de fadiga muscular ao longo do tempo.

2.4.4 Função de perda e processo de treinamento

O treinamento da PINN foi realizado por meio de uma função de perda composta por termos orientados tanto pelos dados experimentais quanto por restrições associadas ao comportamento esperado da fadiga muscular. Essa abordagem permite que o modelo não apenas reproduza os padrões observados nos dados, mas também respeite características físicas inerentes ao fenômeno estudado.

O primeiro componente da função de perda, denominado (L_{data}), corresponde ao Erro Quadrático Médio (MSE) entre as previsões da rede e o índice de fadiga previamente construído. Esse termo é responsável por garantir que a saída da rede permaneça consistente com as informações extraídas dos sinais eletromiográficos.

Além do ajuste aos dados, foram incorporadas restrições físicas por meio da análise das derivadas da saída da rede em relação ao tempo normalizado. O termo (L_{mono}) foi definido para penalizar valores negativos da derivada temporal da fadiga, impondo a hipótese de que, durante o exercício contínuo, a fadiga apresenta comportamento predominantemente não decrescente. Dessa forma, o modelo é desencorajado a produzir reduções abruptas ou fisiologicamente improváveis no índice de fadiga ao longo do tempo.

Adicionalmente, foi introduzido o termo de regularização (L_{reg}), baseado na segunda derivada temporal da saída da rede. Esse componente atua como um mecanismo de suavização, penalizando variações excessivamente bruscas na inclinação da curva prevista e favorecendo a obtenção de trajetórias temporalmente contínuas e compatíveis com a evolução gradual da fadiga muscular observada experimentalmente.

A função de perda total utilizada no treinamento pode ser expressa por:

$$L_{total} = L_{data} + \lambda_{mono} * L_{mono} + \lambda_{reg} * L_{reg}$$

em que λ_{mono} e λ_{reg} representam coeficientes de ponderação responsáveis por controlar a influência das restrições físicas sobre o processo de otimização. Dessa forma, a minimização da função de perda busca simultaneamente maximizar a aderência aos dados experimentais e garantir coerência nas estimativas produzidas pela rede.

O treinamento foi realizado utilizando o algoritmo de otimização Adam, amplamente empregado em aplicações de aprendizado profundo devido à sua capacidade de adaptação dinâmica das taxas de atualização dos parâmetros. Foi adotada uma taxa de aprendizado inicial, complementada por um mecanismo de ajuste. Esse procedimento reduz automaticamente a taxa de aprendizado quando a função de perda apresenta estagnação por um número pré-definido de épocas, favorecendo a convergência do modelo e evitando oscilações durante as etapas finais do treinamento.

2.4.5 Interpretação do modelo PINN

A PINN desenvolvida neste trabalho busca aprender uma função contínua capaz de relacionar as características temporais e espectrais extraídas dos sinais eletromiográficos com a evolução do estado de fadiga muscular ao longo do exercício. Diferentemente de abordagens orientadas por dados, a incorporação de restrições físicas ao processo de treinamento permite que o modelo produza estimativas consistentes não apenas com os dados experimentais, mas também com o comportamento fisiológico esperado do fenômeno analisado.

Nesse contexto, as restrições impostas à função de perda favorecem a obtenção de curvas de fadiga suaves e coerentes, reduzindo oscilações artificiais e penalizando comportamentos incompatíveis com a progressão da fadiga muscular. Como resultado, o modelo combina a capacidade de aprendizado das redes neurais profundas com conhecimentos prévios sobre a dinâmica do sistema biológico, contribuindo para uma representação mais robusta, interpretável e plausível da evolução da fadiga ao longo do tempo.

3 RESULTADOS

Nesta seção são apresentados os resultados obtidos a partir da análise dos sinais de EMG coletados durante o protocolo experimental. As análises incluem representações no domínio

tempo-frequência, métricas fisiológicas extraídas dos sinais e a modelagem da fadiga por meio da PINN.

3.1 Análise no Domínio Tempo-Frequência

Os espectrogramas permitem observar a evolução das componentes de frequência ao longo do tempo para cada grupo muscular analisado.




Figure 3 – Espectrograma do músculo Extensor Digitorium. A linha tracejada indica o instante estimado de fadiga.

No músculo Extensor Digitorium (Figura 3), observa-se uma maior concentração de energia nas faixas de baixa frequência ao longo do tempo. Esse comportamento é consistente com a literatura, que associa a fadiga muscular à redução da frequência mediana do sinal EMG. Além disso, há aumento da intensidade do sinal nas regiões finais do exercício, indicando maior recrutamento de unidades motoras.




Figure 4 – Espectrograma do músculo Palmaris Longus.

Para o músculo Palmaris Longus (Figura 4), observa-se comportamento semelhante, com aumento progressivo da energia em baixas frequências e maior densidade espectral conforme o esforço se prolonga. Esse padrão sugere fadiga localizada, com perda de eficiência muscular.




Figure 5 – Espectrograma do músculo Extensor Carpi Ulnaris.

No Extensor Carpi Ulnaris (Figura 5), o espectrograma apresenta maior dispersão de energia ao longo das frequências, indicando um comportamento mais instável do recrutamento muscular. Ainda assim, é possível observar tendência de deslocamento espectral para frequências mais baixas próximo ao instante de fadiga.

De forma geral, os espectrogramas evidenciam o fenômeno clássico da fadiga muscular: aumento da amplitude do sinal e deslocamento espectral para baixas frequências.

3.2 Métricas Fisiológicas Extraídas




Figure 6 – Evolução temporal das métricas extraídas dos sinais EMG para os diferentes músculos analisados.

A Figura 6 apresenta a evolução temporal de diferentes métricas extraídas dos sinais EMG, incluindo RMS, MAV, frequência mediana e outras características estatísticas.

Observa-se que:

- A **RMS** apresenta tendência de aumento ao longo do tempo, refletindo maior ativação muscular para compensar a fadiga;
- A **MAV** segue comportamento semelhante, indicando aumento da atividade elétrica média;
- A **frequência mediana** apresenta tendência de queda, caracterizando o deslocamento espectral associado à fadiga;
- Há maior variabilidade nas métricas nos instantes finais do exercício, sugerindo instabilidade neuromuscular.

Esses resultados estão alinhados com o comportamento esperado em condições de fadiga muscular progressiva.

3.3 Modelagem da Fadiga com PINN




Figure 7 – (Esquerda) Evolução do score fisiológico de fadiga. (Direita) Comparação entre a predição da PINN e o score fisiológico.

A Figura 7 apresenta a evolução do score fisiológico de fadiga e sua modelagem por meio da PINN.

O **score fisiológico** apresenta crescimento monotônico ao longo do tempo, refletindo o acúmulo progressivo de fadiga durante o exercício. O ponto de fadiga foi identificado aproximadamente em 77.5 segundos, conforme indicado pela linha tracejada.

A **PINN** demonstrou alta capacidade de modelar a dinâmica da fadiga, acompanhando de forma consistente a tendência do score fisiológico. Observa-se que:

- A rede captura corretamente o comportamento crescente da fadiga;
- Há boa aproximação entre predição e dado real, especialmente nas regiões intermediárias do sinal;
- Pequenas discrepâncias podem ser observadas nos instantes iniciais e finais, possivelmente associadas a ruídos ou variações fisiológicas individuais.

Esses resultados indicam que a abordagem baseada em PINN é promissora para modelagem de fenômenos fisiológicos complexos, como a fadiga muscular.

3.4 Síntese dos Resultados

De forma geral, os resultados demonstram que:

- Os sinais EMG apresentam padrões claros de fadiga, tanto no domínio do tempo quanto da frequência;
- As métricas extraídas são consistentes com a literatura fisiológica;
- A PINN foi capaz de modelar a evolução da fadiga com boa precisão;

- d) A integração entre análise de sinais e inteligência artificial permite identificar padrões relevantes para o desempenho muscular.

Esses achados reforçam o potencial do uso de técnicas de análise de dados e aprendizado de máquina na avaliação da fadiga muscular em pilotos de motorsport.

REFERÊNCIAS

ALLEN, J.B. Short term spectral analysis, synthesis, and modification by discrete Fourier transform. **IEEE Transactions on Acoustics, Speech, and Signal Processing**, IEEE, v. 25, n. 3, p. 235–238, 1977.

ANDERSSON, G.; JOHANSSON, H. Muscle activation patterns of the upper extremity during vehicle steering tasks. **Journal of Electromyography and Kinesiology**, v. 25, n. 4, p. 650–658, 2020. DOI: 10.1016/j.jelekin.2019.102375.

AQUINO, Michele *et al.* The Impact of Fatigue on Performance and Biomechanical Variables—A Narrative Review with Prospective Methodology. **Biomechanics**, 2022.

DE LUCA, Carlo J. The use of surface electromyography in biomechanics. **Journal of Applied Biomechanics**, Human Kinetics Publishers, v. 13, n. 2, p. 135–163, 1997.

DE LUCA, Carlo J.; MERLETTI, Roberto; FARINA, Dario. **Surface Electromyography: Physiology, Engineering, and Applications**. Chichester, UK: John Wiley & Sons, Ltd, 2016. chap. 2. ISBN 9781119082934. DOI: 10.1002/9781119082934.

DELSYS INC. **Trigno Wireless Biofeedback System User's Guide**. Natick, MA, USA, 2019. Acessado em: 27 Oct. 2025. Available from: <https://www.delsys.com/downloads/USERSGUIDE/trigno/wireless-biofeedback-system.pdf>.

ENOKA, Roger M. **Neuromechanics of Human Movement**. 5. ed. [S. l.]: Human Kinetics, 2015. chap. 1.

ENOKA, Roger M.; DUCHATEAU, Jacques. Muscle fatigue: what, why and how it influences muscle function. **The Journal of Physiology**, v. 585, n. 1, p. 11–23, 2007. DOI: 10.1113/jphysiol.2007.139477.

FARINA, Dario. **Surface Electromyography: Physiology, Engineering, and Applications**. Chichester, UK: John Wiley & Sons, Ltd, 2016. Capítulo: Biophysics of the Generation of EMG Signals. ISBN 9781119082934. DOI: 10.1002/9781119082934.ch02.

FAVATA, Alessandra *et al.* IMU-Based Systems for Upper-Limb Kinematic Analysis in Clinical Applications: A Systematic Review. **IEEE Sensors Journal**, v. 24, n. 18, p. 24082–24096, 2024. DOI: 10.1109/JSEN.2024.3432832. Available from: <https://doi.org/10.1109/JSEN.2024.3432832>.

FÉDÉRATION INTERNATIONALE DE L'AUTOMOBILE (FIA). **FIA presents a worldwide study on economic and social impact of motor sport**. [S. l.: s. n.], 2021. Acessado

em: 2025-10-27. Available from: <https://api.fia.com/news/fia-presents-worldwide-study-economic-and-social-impact-motor-sport>.

FEHRENBACH, Janet; HERRING, Susan W. (eds.). **Anatomy, Bony Pelvis and Lower Limb, Foot Muscles**. [S. l.]: NCBI Bookshelf, 2020. Capítulo “Foot Muscles”, disponível em: NCBI. Available from: <https://www.ncbi.nlm.nih.gov/books/NBK539705/>.

FERGUSON, D. P.; DAVIS, A. M.; LIGHTFOOT, J. T. Optimizing the physical conditioning of the NASCAR Sprint Cup pit crew athlete. **Journal of Strength & Conditioning Research**, v. 29, n. 3, p. 567–577, 2015. DOI: 10.1519/JSC.0000000000000659.

FERGUSON, David P.; DAVIS, Adam M.; LIGHTFOOT, J. Timothy. Reactivity, Stability, and Strength Performance Capacity in Motor Sports. **Journal of Sports Sciences**, v. 25, n. 8, p. 793, 2007. DOI: 10.1080/02640410600908088. Available from: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2465029/>.

FRANCESCHINI, Giordano; TERZINI, Mara; ZANETTI, Elisabetta M. Learning curves of elite car racers. **International Journal of Sports Science & Coaching**, v. 12, 2017.

GANDEVIA, Simon C. Spinal and Supraspinal Factors in Human Muscle Fatigue. **Physiological Reviews**, v. 81, n. 4, p. 1725–1789, 2001. DOI: 10.1152/physrev.2001.81.4.1725. Available from: <https://journals.physiology.org/doi/pdf/10.1152/physrev.2001.81.4.1725>.

HOYES, Kevin; COLLINS, Dave. Fit to race: Identifying the balance, type and sources of knowledge in fitness for Motorsport. **Sports Science & Coaching**, v. 13, 2018.

INC., Delsys. **Trigno Personal System – User Guide**. [S. l.: s. n.], 2021. <https://delsys.com/downloads/>. Guia do usuário do Trigno Personal System. Acesso em: 27 out. 2025.

INC., Delsys. **Trigno Wireless EMG System – Technical Specifications**. [S. l.: s. n.], 2022. <https://delsys.com/hardware/trigno-wireless-emg-system/>. Ficha técnica oficial dos sensores Trigno. Acesso em: 27 out. 2025.

INC., Delsys. **Trigno Wireless EMG System – User Guide**. Natick, MA, USA, 2022. Guia de operação e especificações do sistema Trigno EMG. Disponível em: <https://delsys.com/downloads/>. Acesso em: 27 out. 2025.

INC., Delsys. **Trigno Wireless System – User’s Guide**. Natick, MA, USA, 2022. Manual do usuário do sistema Trigno. Disponível em: <https://delsys.com/downloads/>. Acesso em: 27 out. 2025.

KENHUB. **Anatomy of the Lower Limb**. Acessado em: 2025-10-27. 2023. Available from: <https://www.kenhub.com/en/library/anatomy/lower-limb>.

KENHUB. **Anatomy of the Upper Limb**. Acessado em: 2025-10-27. 2023. Available from: <https://www.kenhub.com/en/start>.

KENHUB. **Muscles of the Hand: Anatomy and Function**. Acessado em: 2025-10-27. 2023. Available from: <https://www.kenhub.com/en/library/anatomy/muscles-of-the-hand>.

KIM, S.; LEE, D. Muscle Activation of Lower Limbs during Pedal Operation in Driving. **Applied Sciences**, MDPI, v. 12, n. 8, p. 3921, 2022. DOI: 10.3390/app12083921.

KNUDSON, Duane. **Fundamentals of Biomechanics**. 2. ed. [S. l.]: Springer, 2007. chap. 1.

LECOCQ, Marie *et al.* Neuromuscular fatigue profiles depends on seat feature during long duration driving on a static simulator. **Applied Ergonomics**, Elsevier, v. 86, p. 103077, 2020. DOI: 10.1016/j.apergo.2020.103077.

MACY, Alan. **The Handbook of Human Physiological Recording**. [S. l.: s. n.], 2017. Acessado em: 2025-02-06. Available from: <https://alanmacy.com/book/the-handbook-of-human-physiological-recording/>.

MENG, Lin *et al.* An Inertial-Based Upper-Limb Motion Assessment Model: Performance Validation Across Various Motion Tasks. **IEEE Sensors Journal**, v. 23, n. 7, p. 7098–7109, 2023. DOI: 10.1109/JSEN.2023.3245548. Available from: <https://doi.org/10.1109/JSEN.2023.3245548>.

MERLETTI, Roberto; FARINA, Dario. Current developments in surface electromyography. **Frontiers in Physiology**, v. 14, p. 10763750, 2023. DOI: 10.3389/fphys.2023.10763750. Available from: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10763750/>.

MERLETTI, Roberto; PARKER, Philip A. **Electromyography: Physiology, Engineering, and Non-Invasive Applications**. [S. l.]: John Wiley & Sons, 2004. chap. 5. Chapter 5: Signal Processing and Feature Extraction, pp. 95–124. DOI: 10.1002/0471678384.ch5.

MILLS, C. *et al.* Forearm Muscle Activity During Motorsport: A Case Study. **Applied Sciences**, v. 15, n. 16, p. 8801, 2025. DOI: 10.3390/app15168801. Available from: <https://www.mdpi.com/2076-3417/15/16/8801>.

PERFORMANCE RACING INDUSTRY (PRI). **New PRI Study Finds Motorsports Industry Generates \$69.2 Billion for U.S. Economy, Supports Over 318,000 Jobs**. [S. l.: s. n.], 2025. Acessado em: 2025-10-27. Available from:

<https://www.performanceracing.com/magazine/industry-news/06-18-2025/new-pri-study-finds-motorsports-industry-has-692-billion-economic>.

PHINYOMARK, Angkoon; PHUKPATTARANONT, Pornchai; LIMSAKUL, Chusak. Feature Extraction and Selection for Myoelectric Control Based on Wearable EMG Sensors. **Sensors**, MDPI, v. 12, n. 9, p. 12376–12403, 2012. DOI: 10.3390/s120912376. Available from: <https://doi.org/10.3390/s120912376>.

PUCE, Luca *et al.* Surface Electromyography Spectral Parameters for the Study of Muscle Fatigue in Swimming. **Frontiers in Sports and Active Living**, v. 3, p. 644765, 2021. DOI: 10.3389/fspor.2021.644765. Available from: <https://www.frontiersin.org/articles/10.3389/fspor.2021.644765/full>.

REED, M. P.; MANARY, M. A. Upper limb joint angles and muscular activity during simulated driving. **Monash University Accident Research Centre**, 2018. Acessado em: 2025-10-27. Available from: <https://research.monash.edu/en/publications/upper-limb-movements-during-driving>.

RODRIGUES, S. B. *et al.* EMG Signal Processing for the Study of Localized Muscle Fatigue. **Frontiers in Physiology**, 2022. DOI: 10.3389/fphys.2022.9603294. Available from: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9603294/>.

SHAIR, E. F. *et al.* EMG Processing Based Measures of Fatigue Assessment during Manual Lifting. **BioMed Research International**, v. 2017, n. 1, 2017. DOI: <https://doi.org/10.1155/2017/3937254>.

SMITH, J.; PATEL, R. Functional anatomy of the upper limb joints. **Journal of Anatomy**, v. 234, p. 120–134, 2019. DOI: 10.1002/joa.12011.

WATANABE, K.; NAGAI, M. Age-related differences in lower limb muscle activity during emergency braking. **Geriatrics and Gerontology International**, v. 21, n. 6, p. 532–540, 2021. DOI: 10.1111/ggi.14208.

WINGELAAR-JAGT, Yara Q. *et al.* Fatigue in Aviation: Safety Risks, Preventive Strategies and Pharmacological Interventions. **Frontiers in Physiology**, v. 12, 2020.